

Previsão de cotação de ações da bolsa de valores usando redes neurais recorrentes - RNN

Stock Market Forecasting Using Recurrent Neural Networks - RNN

Lucas Mrowskovsy Paim*

2019

Resumo

Este trabalho tem por objetivo criar uma rede neural de aprendizagem profunda para prever valores futuros de um papel na bolsa de valores, o papel escolhido foi PETR4 (Petrobras). A biblioteca utilizada para a criação das hipóteses foi a tensorflow, que segundo [Géron \(2019\)](#), é uma ótima biblioteca para cálculo número de código aberto, o modelo atingiu um erro médio de apenas R\$0,68, que apesar de ser baixo o mercado de ações é extremamente volátil, sendo necessário adicionar N outras características ao treinamento, sendo assim, não podendo ser utilizado em produção.

Palavras-chave: deep-learning. tensorflow. rnn. séries temporais.

Abstract

This work aims to create a deep learning neural network to predict future values of a role in the stock exchange, the role chosen was PETR4 (Petrobras). The library used for hypothesis creation was tensorflow, which according to [Géron \(2019\)](#), is a great open source number library. The model reached an average error of only R\$ 0.68, which despite being low the stock market is extremely volatile, being necessary to add N other characteristics to the training, so it cannot be used in production.

Keywords: deep-learning. tensorflow. rnn. temporal series.

*Programa de Pós Graduação em Inteligência Aritificial, Curitiba - PR, 80215-901; Especializando em Inteligência Artificial Aplicada na PUCPR; Tecnólogo em Sistemas para Internet pela Universidade Positivo; E-mail: lucasmpaim1@gmail.com

1 Introdução

Segundo Ehlers (2009), uma série temporal é uma coleção de observações ao longo do tempo, isto é, são dados que variam de acordo com o passar do tempo, como: comportamentos cerebrais Ulrich et al. (2014), identificação de ritmos musicais, auxílio na composições musicais Corrêa e Saito (2007), taxa mensal de desemprego, eletrocardiograma, etc. As redes neurais recorrentes tentam identificar estes padrões fazendo conexões com neurônios anteriores. Este trabalho irá utilizar redes neurais com aprendizagem profunda, para tentar prever os valores futuros das cotações do papel PETR4 (Petrobrás), usando dados extraídos do Google Finance, com dados a partir de 2006.

2 Método

A base utilizada para este trabalho, foram os dados históricos das ações da Petrobrás (PETR4) extraídos a partir do google finance, para o período de 05/09/2006 até 07/11/2019, estes dados podem ser visualizados na Figura 1.

Utilizando a biblioteca tensorflow (v. 2.0.0), foi montada uma rede neural recorrente (RNN), utilizando duas camadas de neurônios de memória LSTM (Long Short Term Memory), o modelo gerado pode ser consultado na imagem: Figura 2

Em um primeiro momento, a base foi dividida em teste e validação em que os últimos 6 valores da base foram separados em: 5 para dados e 1 previsão e o resto da base é utilizada para treinamento, em que também é dividida na proporção 5:1 e treinada durante 100 épocas, estas configurações foram escolhidas empiricamente, para a escolha desses hiperparâmetros, uma abordagem melhor seria com o uso de algoritmos de busca como os algoritmos genéticos.

O gráfico de loss durante o treinamento, comparando a base de validação e a de treinamento pode ser visualizada na Figura 3, nele podemos notar que não houve overfitting na rede, as camadas "Dropout" que aparecem na Figura 2 que segundo Maklin (2019) definindo aleatoriamente as arestas de saída dos neurônios ocultos como 0, é possível ver graficamente a ação desta célula na Figura 5.

As células LSTM, proposta em 1997 por Sepp Hochreiter e Jurgen Schmidhuber e aperfeiçoada desde então, que segundo Géron (2019), sua ideia-chave é que a rede possa aprender o que armazenar a longo prazo durante o treinamento.

Para a avaliação do erro foi utilizado a métrica MAE (Mean Absoluty Error), que é a média aritmética da diferença entre o valor previsto e o valor real, ela pode ser representada pela fórmula:

$$mae = \frac{1}{n} \sum_{i=0}^M |y_1 - y_i^*| \quad (1)$$

3 Resultados

O modelo atingiu um erro médio de R\$0,56, que é um erro médio aceitável para este trabalho.

O gráfico de previsões pode ser visualizado na Figura 4, os valores estão detalhados na tabela a seguir:

Predict	True	Error
-----	-----	-----
26.6976	27.06	0.362422
27.0461	26.88	0.166108
27.1364	28.06	0.923646
28.2649	27.69	0.574939
28.1389	27.22	0.918869
27.8295	27.29	0.539485
27.8478	27	0.847763
27.6121	27.48	0.132074
28.0022	27.27	0.732196
27.8862	27.34	0.546166
27.9616	27.7	0.261551
28.2554	27.66	0.595356
28.2675	27.55	0.717453
28.2005	27.51	0.690477
28.1581	26.72	1.43813
27.4978	26.74	0.757753
27.4212	26.51	0.911185
27.1793	26.17	1.00934
26.8635	26.02	0.843485
26.6705	26.52	0.150477
27.0216	26.74	0.281629
27.238	27.26	0.0219674
27.7156	27.31	0.405646
27.8302	27.6	0.230248
28.1123	27.93	0.182253
-----	-----	-----

Mesmo a rede tendo resultados satisfatórios, é necessário se considerar que o mercado de ações é extremamente volátil e que não segue um padrão em si, sendo facilmente influenciado por fatos políticos, econômicos etc. que não necessariamente faça com que a ação tenda a seguir um padrão, mesmo tendo isso em vista, a rede se mostrou excelente em demonstrar tendências a longo prazo da ação, sendo um bom indicativo para swing-trade, porém péssimo para day-trade.

Referências

CORRÊA, D. C.; SAITO, J. H. Aplicação de redes neurais para auxílio nas composições musicais utilizando compassos como primitivas e inspiração em relevos naturais. In: TORRES, M. H. C. (Ed.). *Proceedings of the 11th Brazilian Symposium on Computer Music*. São Paulo - SP - Brazil: Sociedade Brasileira de Computação, 2007. p. 251–254. Citado na página 2.


EHLERS, R. Análise de séries temporais. In: . [s.n.], 2009. Disponível em: <<http://www.icmc.usp.br/ehlers/stemp/stemp.pdf>>. Acesso em: 08 nov 2019. Citado na página 2.

GÉRON, A. *Mãos à obra: Aprendizagem de máquina com Skit-Learn e Tensorflow*. 1. ed. Rio de Janeiro: Alta Books Editora, 2019. Acesso em: 21 ago 2013. Citado 2 vezes nas páginas 1 e 2.

MAKLIN, C. Dropout neural network layer in keras explained. In: . [s.n.], 2019. Disponível em: <<https://towardsdatascience.com/machine-learning-part-20-dropout-keras-layers-explained-8c9f6dc4c9ab>>. Acesso em: 08 nov 2019. Citado 2 vezes nas páginas 2 e 7.


ULRICH, K. R. et al. Analysis of brain states from multi-region lfp time-series. In: GHAHRAMANI, Z. et al. (Ed.). *Advances in Neural Information Processing Systems 27*. Curran Associates, Inc., 2014. p. 2483–2491. Disponível em: <<http://papers.nips.cc/paper/5624-analysis-of-brain-states-from-multi-region-lfp-time-series.pdf>>. Citado na página 2.

Figura 1 – Gráfico histórico PETR4 R\$ x Dias úteis após 05/09/2006



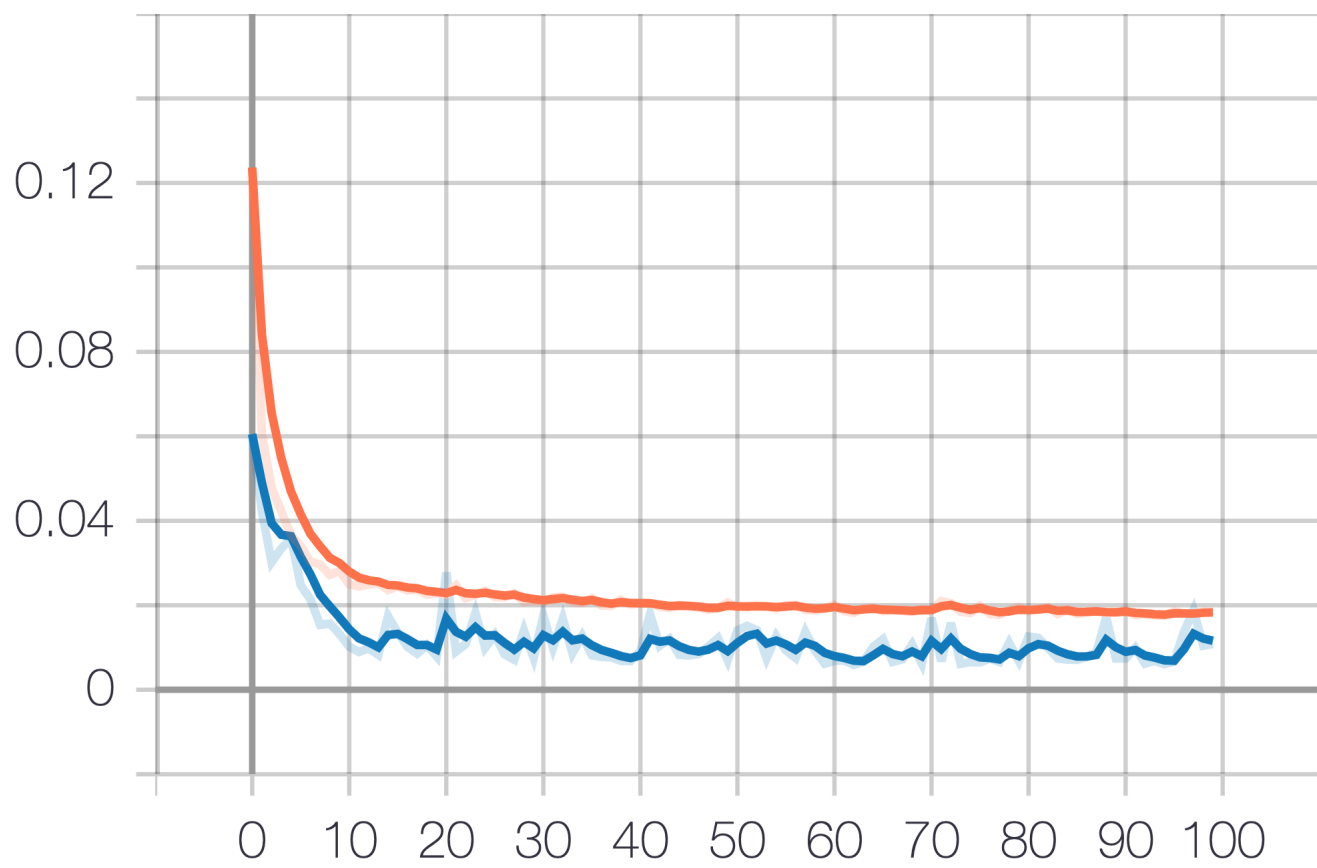
Fonte: O Autor

Figura 2 – Modelo



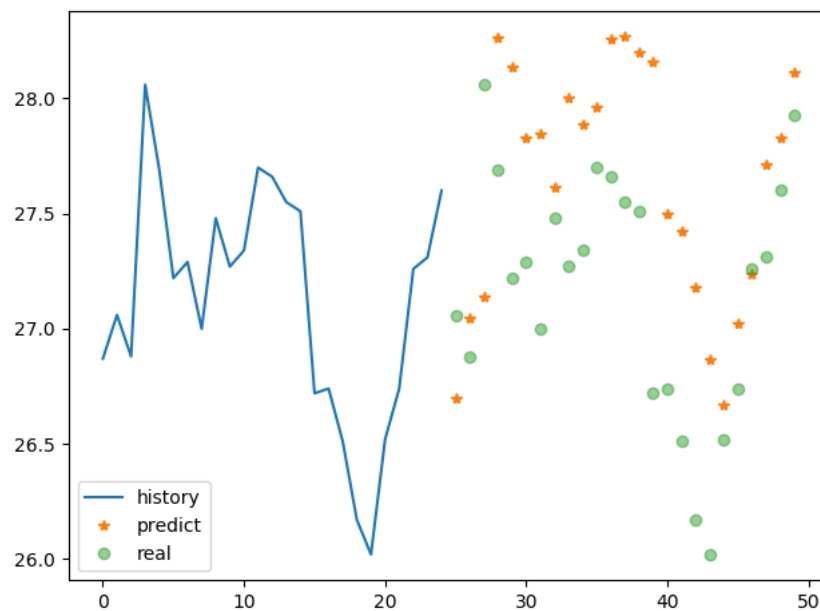
Fonte: O Autor

Figura 3 – Loss




Fonte: O Autor

Figura 4 – Loss



Fonte: O Autor

Figura 5 – Loss



Fonte: [Maklin \(2019\)](#)