

Previsão de cotação de ações da bolsa de valores usando redes neurais recorrentes - RNN

Stock Market Forecasting Using Recurrent Neural Networks - RNN

Lucas Mrowskovsy Paim*

2019

Resumo

Este trabalho tem por objetivo criar uma rede neural de aprendizagem profunda para prever valores futuros de um papel na bolsa de valores, o papel escolhido foi PETR4 (Petrobras). A biblioteca utilizada para a criação das hipóteses foi a tensorflow, que segundo [Géron \(2019\)](#), é uma ótima biblioteca para cálculo número de código aberto, (adicionar resultados)

Palavras-chave: deep-learning. tensorflow. rnn. séries temporais.

Abstract

This work aims to create a deep learning neural network to predict future values of a role in the stock exchange, the role chosen was PETR4 (Petrobras). The library used for hypothesis creation was tensorflow, which according to [Géron \(2019\)](#), is a great open source number library

Keywords:deep-learning. tensorflow. rnn. temporal series.

*Programa de Pós Graduação em Inteligência Aritificial, Curitiba - PR, 80215-901; Especializando em Inteligência Artificial Aplicada na PUCPR; Tecnólogo em Sistemas para Internet pela Universidade Positivo; E-mail: lucasmpaim1@gmail.com

1 Introdução

Segundo Ehlers (2009), uma série temporal é uma coleção de observações ao longo do tempo, isto é, são dados que variam de acordo com o passar do tempo, como: comportamentos cerebrais Ulrich et al. (2014), identificação de ritmos musicais, auxílio na composições musicais Corrêa e Saito (2007), taxa mensal de desemprego, eletrocardiograma, etc. As redes neurais recorrentes tentam identificar estes padrões fazendo conexões com neurônios anteriores. Este trabalho irá utilizar redes neurais com aprendizagem profunda, para tentar prever os valores futuros das cotações do papel PETR4 (Petrobrás), usando dados extraídos do Google Finance, com dados a partir de 2006.

2 Método

A base utilizada para este trabalho, foram os dados históricos das ações da Petrobrás (PETR4) extraídos a partir do google finance, para o período de 05/09/2006 até 07/11/2019, estes dados podem ser visualizados na Figura 1.

Utilizando a biblioteca tensorflow (v. 2.0.0), foi montada uma rede neural recorrente (RNN), utilizando duas camadas de neurônios de memória LSTM (Long Short Term Memory), o modelo gerado pode ser consultado na imagem: Figura 2

Em um primeiro momento, a base foi dividida em teste e validação em que os últimos 6 valores da base foram separados em: 5 para dados e 1 previsão e o resto da base é utilizada para treinamento, em que também é dividida na proporção 5:1 e treinada durante 100 épocas, estas configurações foram escolhidas empiricamente, para a escolha desses hiperparâmetros, uma abordagem melhor seria com o uso de algoritmos de busca como os algoritmos genéticos.

O gráfico de loss durante o treinamento, comparando a base de validação e a de treinamento pode ser visualizada na Figura 3, nele podemos notar que não houve overfitting na rede, as camadas "Dropout" que aparecem na Figura 2 que segundo Maklin (2019) definindo aleatoriamente as arestas de saída dos neurônios ocultos como 0.

As células LSTM, proposta em 1997 por Sepp Hochreiter e Jurgen Schmidhuber e aperfeiçoada desde então, que segundo Géron (2019), sua ideia-chave é que a rede possa aprender o que armazenar a longo prazo durante o treinamento.

Para a avaliação do erro foi utilizado a métrica MAE (Mean Absoluty Error), que é a média aritmética da diferença entre o valor previsto e o valor real, ela pode ser representada pela fórmula:

$$mae = \frac{1}{n} \sum_{i=0}^M |y_1 - y_i^*| \quad (1)$$

3 Resultados

O modelo atingiu um erro médio de R\$0,68, que é um erro médio aceitável para este trabalho.

O grafico de previsões pode ser visualizado na Figura 4

Referências

CORRÊA, D. C.; SAITO, J. H. Aplicação de redes neurais para auxílio nas composições musicais utilizando compassos como primitivas e inspiração em relevos naturais. In: TORRES, M. H. C. (Ed.). *Proceedings of the 11th Brazilian Symposium on Computer Music*. São Paulo - SP - Brazil: Sociedade Brasileira de Computação, 2007. p. 251–254. Citado na página 2.


EHLERS, R. Análise de séries temporais. In: . [s.n.], 2009. Disponível em: <http://www.icmc.usp.br/ehlers/stemp/stemp.pdf>. Acesso em: 08 nov 2019. Citado na página 2.

GÉRON, A. *Mãos à obra: Aprendizagem de máquina com Skit-Learn e Tensorflow*. 1. ed. Rio de Janeiro: Alta Books Editora, 2019. Acesso em: 21 ago 2013. Citado 2 vezes nas páginas 1 e 2.

MAKLIN, C. Dropout neural network layer in keras explained. In: . [s.n.], 2019. Disponível em: <https://towardsdatascience.com/machine-learning-part-20-dropout-keras-layers-explained-8c9f6dc4c9ab>. Acesso em: 08 nov 2019. Citado na página 2.


ULRICH, K. R. et al. Analysis of brain states from multi-region lfp time-series. In: GHAHRAMANI, Z. et al. (Ed.). *Advances in Neural Information Processing Systems 27*. Curran Associates, Inc., 2014. p. 2483–2491. Disponível em: <http://papers.nips.cc/paper/5624-analysis-of-brain-states-from-multi-region-lfp-time-series.pdf>. Citado na página 2.

Figura 1 – Gráfico histórico PETR4 R\$ x Dias úteis após 05/09/2006




Fonte: O Autor

Figura 2 – Modelo




Fonte: O Autor

Figura 3 – Loss



Fonte: O Autor

Figura 4 – Loss



Fonte: O Autor